

Опис кључних компоненти система

Давор Хома Е2 53/2025

14. септембар 2026.

1 Персона: креатор садржаја на више платформи

Примарна персона система је креатор садржаја из области видео игара, који активно објављује видео садржај на више платформи, пре свега на *YouTube* и *TikTok*. Ова персона се не ослања на једну платформу, већ користи више канала за дистрибуцију свог садржаја, што је честа пракса међу модерним креаторима садржаја. Њихов циљ је да максимизирају досег и ангажовање публике, користећи различите платформе како би проширили видљивост свог садржаја.

Персона објављује кратке (*TikTok*, *YouTube Shorts*) и дуже (*YouTube long-form content*) *gaming* видео записе, активно прати трендове, али нема систематски увид у податке. Њена стратегија је углавном заснована на интуицији, парцијалним метрикама и виралним трендовима које самостално примећује на платформама. Иако је успешна у привлачењу публике, често се осећа као да јој недостаје дубљи увид у то шта заиста покреће ангажовање и виралност садржаја.

1.1 Циљеви персоне

Могу се издвојити неколико кључних карактеристика видео садржаја које ова персона жели да оптимизује.

1. **Виралност и перформансе:** Желела би да разуме који типови *gaming* записа постају вирални и који фактори (дужина видеа, опис, ознаке, број лајкова, коментара, дељења,...) доприносе том успеху. Такође, желела би да има увид у то како се популарност одређених видео записа мења током времена.
2. **Cross-platform оптимизација (*TikTok vs YouTube*):** Персона би желела да зна да ли исти видео има бољи перформанс на *TikTok*-у или *YouTube*-у, да ли и колико брзо *TikTok* трендови прелазе на *YouTube* и обрнуто.
3. **Оптимални формат садржаја:** Персона жели да разуме који формат видео записа (кратки или дуги) има бољи одзив публике и да ли постоје специфични жанрови или теме унутар *gaming* категорије које су у датом тренутку посебно успешне.

1.2 Проблеми које персона има

Без система који би јој пружио дубљи увид у перформансе њеног садржаја, ова персона се суочава са неколико изазова. Не поседује јасну слику о томе који видео записи су заиста успешни и зашто, што отежава доношење информисаних одлука о будућем садржају. Поред тога, не зна да ли видео записи на једној друштвеној мрежи имају потенцијала на другој, нити има механизам за благовремено препознавање нових трендова и одређивање оптималног тренутка за објављивање садржаја, што може довести до пропуштених прилика за раст. Такође, нема историјски

контекст о видео записима који су били успешни у прошлости, што је важно за разумевање трендова и оптимизацију будућег садржаја.

Систем настоји да реши наведене проблеме тако што ће пружити алате и увиде који ће помоћи овој персони да боље разуме своје и туђе видео записе, оптимизује свој садржај за различите платформе и доноси информисане одлуке о својој креативној стратегији.

1.3 Конкретна питања

Питања на која систем настоји да одговори су подељена у две групе: питања заснована на историјским скуповима података и питања заснована на скуповима података који се периодично прикупљају.

1.3.1 Историјска питања (ИП)

1. Који су 10 најпопуларнији *gaming* видео записи по годинама (*YouTube* 2020-2024, *TikTok* 2025)?
2. Који су 10 најпопуларнији *gaming* канали по годинама (*YouTube* 2020-2024, *TikTok* 2025)?
3. Како се мења просечан број прегледа и ангажовање корисника кроз време на *YouTube* и *TikTok* платформама?
4. Како се дистрибуција „*viral_score*” разликује између популарнијих и мање популарних видео записа?
5. Како дужина видео записа утиче на њихову популарност?
 - a) *YouTube* – кратки (до 5 min), средњи (5 – 20 min), дуги (преко 20 min)
 - b) *TikTok* – кратки (до 30 s), средњи (30 s – 3 min), дуги (преко 3 min)
6. Колико просечно трају видео записи на *YouTube*, а колико на *TikTok* платформи?
7. Колики је просечан број тагова код 100 најпопуларнијих видео записа на *YouTube*, а колики на *TikTok* платформи?
8. Који тагови се најчешће појављују код 100 најпопуларнијих видео записа на *YouTube*, а који на *TikTok* платформи?
9. Које комбинације тагова су најчешће код виралних видео записа?

1.3.2 Питања за периодично прикупљане скупове података (ПП)

1. Које *gaming* теме остварују највећи „*viral_score*” у *YouTube* и *TikTok* скуповима података за праћење трендова?

2. Како се најпопуларније *gaming* теме мењају током времена у скуповима података за праћење трендова?
3. Које кључне речи су најчешће повезане са најпопуларнијим *gaming* видео записима на *YouTube* и *TikTok* платформама?
4. Колико брзо нови *gaming* видео записи достижу статус најпопуларнијих?
5. Да ли се исте *gaming* теме истовремено појављују као најпопуларније на *YouTube* и *TikTok* платформама?
6. Да ли постоји временско кашњење у појави истих *gaming* трендова између *YouTube* и *TikTok* платформи? Ако да, са које платформе обично почињу?
7. Како се ангажовање корисника (лајкови и коментари) мења кроз време?
8. Да ли се број прегледа разликује између радних дана и викенда на различитим платформама?
9. Које нове *gaming* теме се појављују у скуповима података прикупљених претрагом пре него што постану доминантне у скуповима података за праћење трендова?
10. Колико дуго остају најпопуларнији *gaming* видео записи на врху листе најпопуларнијих?

1.4 Мапирање питања на потребе персоне

Иако су претходна питања приказана као засебне целине, њихова основна сврха је да подрже доношење одлука у складу са дефинисаним потребама персоне. Поједина питања могу истовремено да допринесу остваривању више циљева. Табела 1 приказује на који начин свако аналитичко питање доприноси задовољавању одређених потреба персоне.

Питање	Виралност и перформанс	<i>TikTok</i> vs <i>YouTube</i>	Формат садржаја	Допринос
ИП1	✓			идентификација најуспешнијих видео записа
ИП2	✓			идентификација најуспешнијих креатора
ИП3	✓	✓		поређење развоја перформанси платформи
ИП4	✓			анализа дистрибуције виралности
ИП5	✓	✓	✓	одређивање оптималне дужине по платформи
ИП6		✓	✓	поређење трајања
ИП7		✓	✓	поређење броја тагова
ИП8		✓	✓	одређивање најчешће коришћених тагова
ИП9		✓	✓	откривање образаца комбинација тагова
ПП1	✓	✓		идентификација тема које тренутно остварују успех
ПП2	✓	✓		праћење развоја трендова
ПП3		✓	✓	оптимизација наслова и описа
ПП4	✓			мерење брзине достизања виралности
ПП5		✓		паралелна појава трендова
ПП6		✓		детекција извора тренда
ПП7	✓			праћење динамике ангажовања
ПП8	✓	✓		одређивање времена објављивања
ПП9	✓			рано откривање трендова
ПП10	✓			процена трајања популарности

Табела 1: Мапирање аналитичких питања на потребе персоне


1.5 Организација аналитичких контролних табли

У овом раду биће представљене четири аналитичке контролне табле, при чему свака од њих обједињује одређени скуп међусобно повезаних питања дефинисаних у претходном делу. За сваку контролну таблу дат је кратак опис њене намене и графика које садржи, као и одговарајућа слика која илуструје њен изглед.

1.5.1 Контролна табла за анализу виралности и перформанси

На слици 1 приказана је скица прве аналитичке контролне табле намењене анализи виралности и перформанси *gaming* видео записа на платформама *YouTube* и *TikTok*. Њен циљ је да креатору садржаја омогући увид у то који видео записи и канали постижу најбоље резултате, како се њихова популарност мења током времена и колико се успешни видео записи разликују од просечних по вредности метрике „*viral_score*” и ангажовању корисника. Контролна табла садржи филтере за избор платформе и године.

Приказани графици обухватају листу 10 најпопуларнијих видео записа (ИП1) и 10 најуспешнијих канала (ИП2) према вредности метрике „*viral_score*”, кретање просечног броја прегледа и ангажовања корисника кроз време (ИП3, ПП7), као и поређење расподеле вредности метрике „*viral_score*” између популарнијих и мање популарних видео записа (ИП4), чиме се омогућава анализа разлика у нивоу виралности између ове две групе, као и варијабилност резултата унутар сваке групе.




Слика 1: Контролна табла за анализу виралности и перформанси

1.5.2 Контролна табла за оптимизацију формата садржаја

На слици 2 приказана је скица друге контролне табле усмерене на истраживање утицаја формата видео записа на његову виралност, посебно у контексту поређења платформи. Циљ ове контролне табле је да креатору

садржаја помогне да одреди оптималну дужину видео записа, број ознака, као и да препозна које ознаке и кључне речи се најчешће појављују код видео записа на различитим платформама.

Графици приказују однос дужине видео записа и вредности „viral_score” за сваку платформу посебно (ИП5), просечно трајање видео записа (ИП6), просечан број ознака (ИП7), најчешће коришћене појединачне ознаке (ИП8) и њихове комбинације (ИП9), као и најчешће кључне речи (ПП3).




Слика 2: Контролна табла за оптимизацију формата садржаја

1.5.3 Контролна табла за праћење динамике трендова

На слици 3 приказана је скица треће контролне табле посвећене праћењу начина на који *gaming* трендови настају, достижу врхунац и постепено губе на значају. Она омогућава креатору садржаја да боље разуме животни циклус трендова и да идентификује обрасце у времену објављивања ради веће видљивости садржаја.

Кретање популарности најпопуларнијих *gaming* тема кроз време приказано је засебно за сваку платформу, при чему корисник може да одабере до 10 најпопуларнијих тема које жели да упореди (ПП2). Поред тога, контролна табла приказује дистрибуцију броја дана потребних да видео запис достигне врхунац популарности (ПП4) и броја дана колико остаје међу најпопуларнијим (ПП10), као и поређење броја прегледа остварених током радних дана у односу на викенд за сваку платформу посебно (ПП8).

Dashboard 3 – Trend Dynamics & Lifecycle




Слика 3: Контролна табла за праћење динамике трендова

1.5.4 Контролна табла за међуплатформску анализу трендова

На слици 4 приказана је скица четврте контролне табле намењене међуплатформској анализи трендова, као и раном откривању тема које стичу популарност. Њен циљ је да креатору садржаја омогући да препозна теме које се тренутно највише издвајају на свакој од платформи, да сагледа у којој мери се исте теме истовремено појављују као популарне на обе платформе, као и да идентификује теме чија популарност тек почиње да расте.

Графици приказују теме које бележе убрзан раст у скупу података прикупљеном претрагом, а које се још увек нису појавиле међу трендовима, заједно са временским током вредности аритметичке средине „*viral_score*” за те теме (ПП9), теме са највећом вредношћу метрике „*viral_score*” на свакој од платформи посебно (ПП1), преклапање популарних тема између платформи приказано хитмапом (ПП5), као и временско кашњење између платформи на којима се тренд први пут јавља (ПП6).

Dashboard 4 – Cross-Platform Trend Analysis



Слика 4: Контролна табла за међуплатформску анализу трендова

1.6 Кориснички ток коришћења система (*workflow*)

Коришћење система је вођено циљевима корисника. Персона приступа систему са конкретним питањем или проблемом, након чега отвара одговарајуће контролне табле са графицима. Анализа се одвија као низ повезаних корака у којима корисник постепено проширује увид у посматрани проблем. Резултати добијени на једном графику пружају контекст за тумачење наредних анализа, чиме систем подржава постепено доношење одлука заснованих на подацима.

За потребе овог рада, дефинисана су три корисничка тока коришћења система.

1.6.1 Кориснички ток за анализу успешног садржаја

Кораци:

1. Контролна табла 1

- ИП1
- ИП2
- ИП3
- ПП7
- ИП4

Кориснички ток одвија се у потпуности на контролној табли 1 (слика 1). Анализа започиње графиком ИП1, на основу кога корисник идентификује

најуспешније *gaming* видео записе у посматраном периоду и креаторе који су их објавили. Након тога посматра график ИП2 како би утврдио који канали су најуспешнији и проценио да ли се најпопуларнији видео записи углавном појављују код истих креатора. Затим анализира график ИП3, који приказује историјско кретање просечног броја прегледа и ангажовања корисника, чиме добија контекст у ком су ти резултати остварени. Поређењем са графиком ПП7 може да процени да ли су тренутни нивои ангажовања у складу са историјским кретањима или постоје значајна одступања. На крају, посматра график ИП4 који даје увид у расподелу вредности метрике „*viral_score*” код популарнијих и мање популарних видео записа. На основу овог графика корисник може да процени варијабилност вредности унутар обе групе, као и да утврди да ли постоји јасна разлика у нивоу виралности између успешнијих и мање успешних видео записа.

1.6.2 Кориснички ток за креирање новог видеа

Кораци:

1. Контролна табла 4

- ПП9
- ПП1
- ПП5
- ПП6

2. Контролна табла 2

- ИП5
- ИП6
- ИП7
- ИП8
- ИП9
- ПП3

3. Контролна табла 3

- ПП8

Кориснички ток започиње контролном таблом 4 (слика 4). Посматрајући графике ПП9 и ПП1, на основу ПП9 корисник добија увид које теме су брзо растуће, а још увек нису међу највиралнијим темама које приказује график ПП1. Ова два графика олакшавају кориснику да одабере тему за свој нови *gaming* видео запис. Након тога, гледајући графике ПП5 и ПП6, корисник процењује да ли је погодније објавити садржај истовремено на обе платформе или најпре на једној, а затим након одређеног временског интервала и на другој платформи.

Корисник затим прелази на контролну таблу 2 (слика 2) како би оптимизовао формат свог видео садржаја на обе платформе. Графици ИП5 и ИП6 помажу кориснику да одабере дужину његових нових видео записа. На основу графика ИП7, ИП8 и ИП9 корисник одлучује које ознаке и комбинације ознака ће употребити, а помоћу графика ПП3 се одлучује за кључне речи које ће користити у наслову и опису видео записа.

Последњи корак у овом току представља анализа графика ПП8 на контролној табли 3, помоћу кога корисник процењује најпогоднији период за објављивање видео записа на обе платформе.

1.6.3 Кориснички ток за праћење постојећег видеа

Кораци:

1. Контролна табла 1

- ПП7
- ИП3

2. Контролна табла 3

- ПП2
- ПП4
- ПП10

Након што је објавио нове видео записе, овај ток кориснику служи да процени њихове перформансе у односу на тренутне и историјске обрасце сродних видео записа. Да би овај кориснички ток био најефективнији, погодно је да корисник поред графика на контролним таблама посматра и правовремене податке о његовим новообјављеним видео записима на *YouTube* и *TikTok* платформама.

Кориснички ток започиње контролном таблом 1 (слика 1). Посматрајући графике ИП3 и ПП7, корисник може да упореди перформансе својих видео записа са историјским кретањем просечног броја прегледа и ангажовања, као и са тренутним просечним нивоом ангажовања корисника на платформама.

Преласком на контролну таблу 3 (слика 3), на основу графика ПП2, корисник упоређује број прегледа његових видео записа са просечним прегледима тренутно најпопуларнијих видео записа за одабране теме и закључује да ли је креирао популаран видео запис. На основу графика ПП4 корисник може да процени колико дана ће требати његовим видео записима од дана објављивања да достигну своју највећу популарност, а уколико доспеју у најпопуларније видео записе, на основу графика ПП10 може да процени колико ће времена на тој листи остати.

2 Opis skupova podataka

2.1 Историјски скупови података

2.1.1 *YouTube* историјски скуп података

Историјски скуп података коришћен у овом истраживању представља унапређену и обједињену верзију оригиналног *YouTube Trending Dataset*-а објављеног на *Kaggle* платформи [1].

Оригинални скуп података садржи информације о *YouTube* видео записима који су се појављивали у секцији „трендинг“ у различитим регионима и временским периодима. У оквиру овог рада, подаци су додатно проширени и стандардизовани коришћењем *YouTube Data API v3*, при чему су појединачне регионалне датотеке обједињене у јединствен скуп података ради лакше и ефикасније анализе.

Обједињени скуп података обухвата приближно 4,55 GB података и садржи видео записе из периода од 11. августа 2020. године до 5. априла 2024. године. Сваки запис представља један видео у одређеном тренутку када се налазио у трендинг секцији, при чему су укључени основни метаподаци (наслов, име канала, датум објаве, опис, ознаке) и статистички подаци (број прегледа, лајкова, коментара).

Након филтрирања на категорију *gaming* садржаја (*categoryId* = 20), издвојен је специјализовани подскуп података величине приближно 575 MB, који садржи око 400.000 записа. Овај подскуп представља фокус овог истраживања и користи се за анализу дугорочних образаца популарности у домену *gaming* садржаја на *YouTube* платформи.

Финални скуп података је доступан на следећем линку: <https://www.kaggle.com/davorhoma/historical-youtube-gaming-dataset>

2.1.2 *TikTok* историјски скуп података

Велики скуп података преузет из јавно доступне колекције *TikTok-10M dataset* са *Hugging Face* платформе [2]. Оригинални скуп података обухвата приближно 9,78 GB података и покрива *TikTok* видео записе из 2025. године. У оквиру овог истраживања, из комплетног скупа издвојен је подскуп који се односи искључито на *gaming* садржај, коришћењем филтрирања на основу кључних речи из текстуалних података као што су опис, наслов и ознаке.

Након филтрирања, издвојени *gaming* подскуп садржи приближно 370 MB података и обухвата приближно 140.000 видео записа. Овај подскуп представља фокус истраживања у домену *TikTok gaming* садржаја и користи се за анализу образаца популарности, ангажовања корисника и структуре садржаја.

Финални скуп података је доступан на следећем линку: <https://www.kaggle.com/davorhoma/historical-tiktok-gaming-dataset>

2.2 Скупови података за праћење трендова

2.2.1 Youtube скуп података за праћење трендова

Скуп података који служи за анализу виралности *gaming* садржаја и прикупља се путем *YouTube Data API v3*. Скуп обухвата видео записе из секције „трендинг“, уз филтрирање на *gaming* категорију (*categoryId = 20*).

Подаци се прикупљају једном дневно и садрже информације о видео записима из 11 региона (*US, BR, CA, DE, FR, GB, IN, JP, KR, MX, RU*), чиме се омогућава праћење регионалних разлика и промене трендинг листе кроз време. Тренутни скуп података је величине приближно 2,7 MB и садржи 1.911 записа, почевши од 26. маја 2026. године.

Сваки запис представља један видео у одређеном тренутку његовог појављивања на трендинг листи. Укључује метаподатке о видеу (наслов, канал, опис, ознаке, датум објаве, дужина трајања) и статистике ангажовања (број прегледа, лајкова и коментара). Додатно, дефинисана је изведена метрика „*viral_score*“ која комбинује број прегледа, лајкова и коментара ради процене виралности.

Описани скуп података је доступан на следећем линку: <https://www.kaggle.com/davorhoma/monitoring-youtube-real-time-dataset>

2.2.2 TikTok скуп података за праћење трендова

Скуп података који служи за анализу виралности *gaming* садржаја на *TikTok* платформи. Скуп података се прикупља коришћењем *Apify clockworks/tiktok-scraper* алата, при чему се процес извршава једном дневно почевши од 25. маја 2026. године.

Прикупљање података заснива се на унапред дефинисаном скупу од 100 *gaming* кључних речи, које су идентификоване на основу анализа текстуалних података из историјског скупа. На овај начин се обезбеђује континуирано праћење промена у популарности и виралности *gaming* садржаја унутар *TikTok* заједнице.

Тренутни скуп података има величину од приближно 11 MB и садржи 10.263 записа.

Сваки запис обухвата основне информације о видео садржају (назив канала, опис видеа, ознаке, дужина видеа, датум објаве) и статистике ангажовања (број прегледа, лајкова, коментара и дељења). Поред тога, укључене су и временске ознаке датума када је видео снимљен и када је прикупљен и додатно изведена метрика „*viral_score*“.

Описани скуп података је доступан на следећем линку: <https://www.kaggle.com/davorhoma/monitoring-tiktok-real-time-dataset>

2.3 Скупови података прикупљени претрагом

2.3.1 *YouTube Search* скуп података

YouTube Search представља скуп података прикупљен путем *YouTube Data API v3*, при чему се једном дневно врши претрага приближно 100 унапред дефинисаних кључних речи које покривају различите жанрове игара, типове садржаја и популарне *gaming* теме.

Тренутна величина скупа података износи приближно 7,1 MB и садржи 9.074 записа. За сваку кључну реч преузимају се подаци о најрелевантнијим видео записима из *gaming* категорије (*categoryId* = 20).

Скуп података садржи исте атрибуте као и *YouTube* скуп података за праћење трендова, са изузетком атрибута *region_code*, будући да се видео записи не преузимају са регионалних трендинг листа већ на основу резултата претраге.

За разлику од скупа података за праћење трендова који прати тренутно најпопуларније видео записе, овај скуп података омогућава анализу садржаја који је релевантан за различите *gaming* теме, без обзира на то да ли се тренутно налази на регионалним трендинг листама.

Описани скуп података је доступан на следећем линку: <https://www.kaggle.com/davorhoma/youtube-search-gaming-dataset>

2.3.2 *TikTok Search* скуп података


TikTok Search скуп података прикупља се једном дневно коришћењем *Playwright* алата, који аутоматизује претрагу садржаја на *TikTok* платформи за приближно 100 унапред дефинисаних кључних речи из *gaming* домена.

Тренутна величина скупа података износи 8,6 MB и садржи 21.328 записа. За сваку кључну реч преузимају се видео записи који се појављују у резултатима претраге, као и у оквиру препорученог садржаја који се динамички учитава током скроловања странице, након чега се из мрежног саобраћаја платформе издвајају релевантни метаподаци и статистике о сваком видеу.

У односу на *TikTok* скуп података за праћење трендова, овај скуп садржи атрибут *search_query*, који омогућава директно повезивање сваког видео записа са кључном речи на основу које је пронађен. На тај начин омогућена је анализа популарности различитих *gaming* тема, поређење резултата претраге и идентификација кључних речи које доводе до највећег корисничког ангажовања.

Описани скуп података је доступан на следећем линку: <https://www.kaggle.com/davorhoma/tiktok-search-gaming-dataset>

3 Дијаграм архитектуре система



Слика 5: Дијаграм архитектуре система за обраду података

На слици 5 приказан је дијаграм архитектуре система који ће бити имплементиран за потребе овог истраживања. Архитектура је подељена на два главна сегмента: систем за групну обраду историјских података (*batch processing*) и систем за обраду токова података (*stream processing*).

За реализацију предложене архитектуре одабране су следеће технологије:

- **Оркестрација и симулација:** *Apache Airflow* за управљање групним пословима и *Python* скрипте за симулацију токова у реалном времену.
- **Прихват и обрада података:** *Apache Kafka* као дистрибуирани систем за поруке и *Apache Kafka Streams* за аналитичку обраду.
- **Складиштење података:** *Hadoop HDFS* (структурисан кроз *Raw* и *Transformation* зоне) и *MongoDB* као база за финалне, агрегиране податке (*Curated* зона).
- **Визуелизација:** *Apache Superset* платформа за извештавање.

Библиографија

- [1] Youtube. Youtube trending video dataset (updated daily), 2024. Pristupljeno: 2026-06-06.
- [2] The Data Company. Tiktok-10m: A large-scale short video dataset for video understanding, 2025. A dataset of 10 million TikTok posts for multimodal learning and social media analysis.